

Series de Tiempo Descomposición

Orlando Belli Hesse

Test de estacionariedad

- Utilizaremos el test de Dickey Fuller aumentado
 - H_0 : La serie no es estacionaria
 - H_1 : La serie es estacionaria

<https://www.statsmodels.org/dev/generated/statsmodels.tsa.stattools.adfuller.html>

Si $p_value < 5 \%$ entonces se rechaza H_0 , se concluye que la serie es estacionaria

P_value es la probabilidad de que ocurra H_0


```
sts.adfuller(df.market_value)
```

```
(-1.7369847452352454,  
0.4121645696770613,  
18,  
5002,  
{ '1%': -3.431658008603046,  
  '10%': -2.567077669247375,  
  '5%': -2.862117998412982 },  
39904.880607487445)
```

Estacionalidad

Descompone la serie en 3 efectos:

- Tendencia (T_t)
- Estacional (S_t)
- Residual (ϵ_t)




Descomposición Clásica

- Aditivo

$$X_t = S_t + T_t + e_t$$


- Multiplicativo

$$X_t = S_t \times T_t \times e_t$$




Autocorrelación simple ACF

- Si las líneas verticales salen de la sombra azul, quiere decir que deben tener un coeficiente significativo
- La gráfica de autocorrelación simple nos determina el modelo MA



Autocorrelación Parcial


- Determina el impacto de autocorrelación que tiene el valor actual vs un primer, segundo, tercer, etc. Retraso, los que salen de los umbrales son significativos
- La gráfica de autocorrelación parcial nos determina el modelo AR



Modelo AR(p)

$$X_t = \alpha + \varrho_1 X_{t-1} + \cdots + \varrho_p X_{t-p} + \varepsilon_t$$


- Quiere decir que el valor actual depende de sus valores pasados:
- Si depende de un solo valor anterior , es una regresión lineal simple
- Si depende de varios valores anteriores es una regresión lineal múltiple



Modelo MA(q)

$$y_t = \mu + a_t + \theta_1 a_{t-1} + \theta_2 a_{t-2} + \dots + \theta_q a_{t-q}$$

- y_t : valor actual
- μ : Valor constante sobre la cual se mueve la variable
- $\theta_1, \theta_2, \dots, \theta_n$: Coeficientes a estimar
- $a_t, a_{t-1}, \dots, a_{t-n}$: Errores observados de los periodos $t, t-1, \dots, t-n$
- Quiere decir que el valor actual depende de sus errores pasados
- q : parámetro de la media móvil para predecir y calcular errores



Modelos Mixtos ARMA(p,q)

La consideración de la parte estacional supone la modelización de la parte regular y la estacional, lo que daría lugar a la combinación de modelos ARMA(p,q) x SARMA(P,Q):

$$y_t = \underbrace{\mu + \phi_1 y_{t-1} + \dots + \phi_p y_{t-p}}_{\text{AR}(p)} + \underbrace{\Phi_1 y_{t-s} + \dots + \Phi_P y_{t-Ps}}_{\text{SAR}(P)} + \underbrace{a_t + \theta_1 a_{t-1} + \dots + \theta_q a_{t-q}}_{\text{MA}(q)} + \underbrace{\Theta_1 a_{t-s} + \dots + \Theta_Q a_{t-Qs}}_{\text{SMA}(Q)}$$

EJERCICIOS: Expresa, en forma algebraica, los siguientes modelos:

$$\text{ARMA}(1,2) \quad y_t = \mu + \phi_1 y_{t-1} + a_t + \theta_1 a_{t-1} + \theta_2 a_{t-2} \quad \text{SARMA}(4,0) \quad y_t = \mu + \Phi_1 y_{t-4} + a_t$$

$$\text{ARMA}(0,1) \times \text{SARMA}(4,8) \quad y_t = \mu + \Phi_1 y_{t-4} + a_t + \theta_1 a_{t-1} + \Theta_1 a_{t-4} + \Theta_2 a_{t-8}$$

$$\underline{\text{ARMA}(1,1) \times \text{SARMA}(12,12)} \quad y_t = \mu + \phi_1 y_{t-1} + \Phi_1 y_{t-12} + a_t + \theta_1 a_{t-1} + \Theta_1 a_{t-12} -$$

Estacionariedad en los modelos ARIMA

Como los modelos ARMA sólo pueden ser aplicados a series que no muestren ningún tipo de tendencia, será necesario recurrir a **métodos de eliminación de las tendencias (en media y varianza)**.

a) **Tendencia en varianza** o heteroscedasticidad. Prácticamente todas las series procedentes del mundo socioeconómico presentan heteroscedasticidad, en mayor o menor grado.

Dado que tampoco existen contrastes univariantes de homoscedasticidad muy efectivos, en la práctica se opta por ~~eliminar~~ (o mitigar) esta tendencia en todas las series, sometiéndolas a algún tipo de transformación.

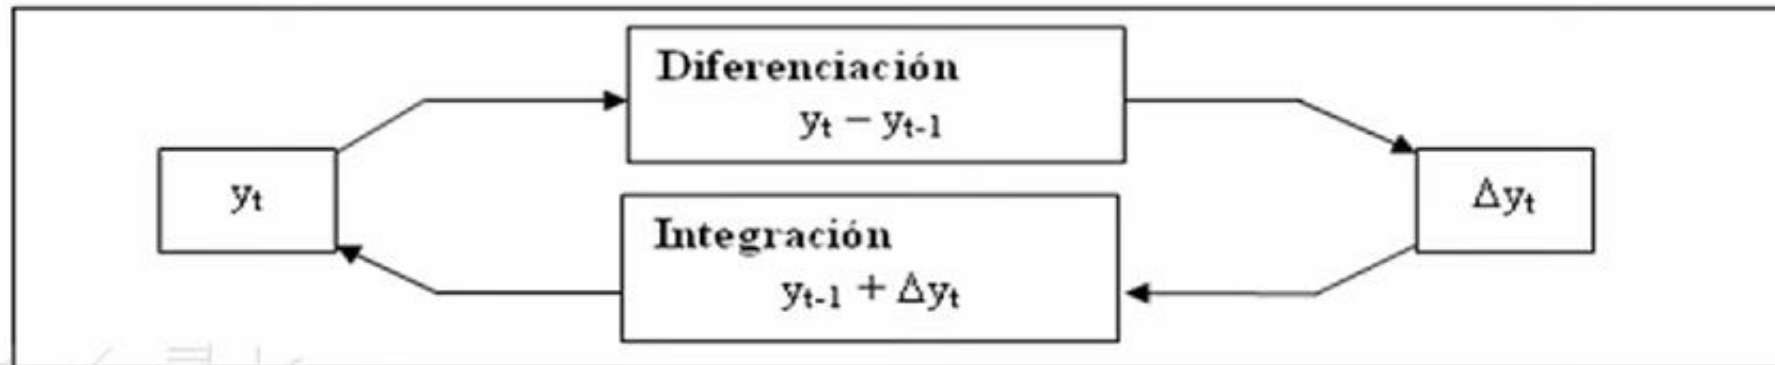
Las transformaciones más habituales son la **transformación logarítmica o cualquier otra perteneciente a la familia de Box-Cox**:

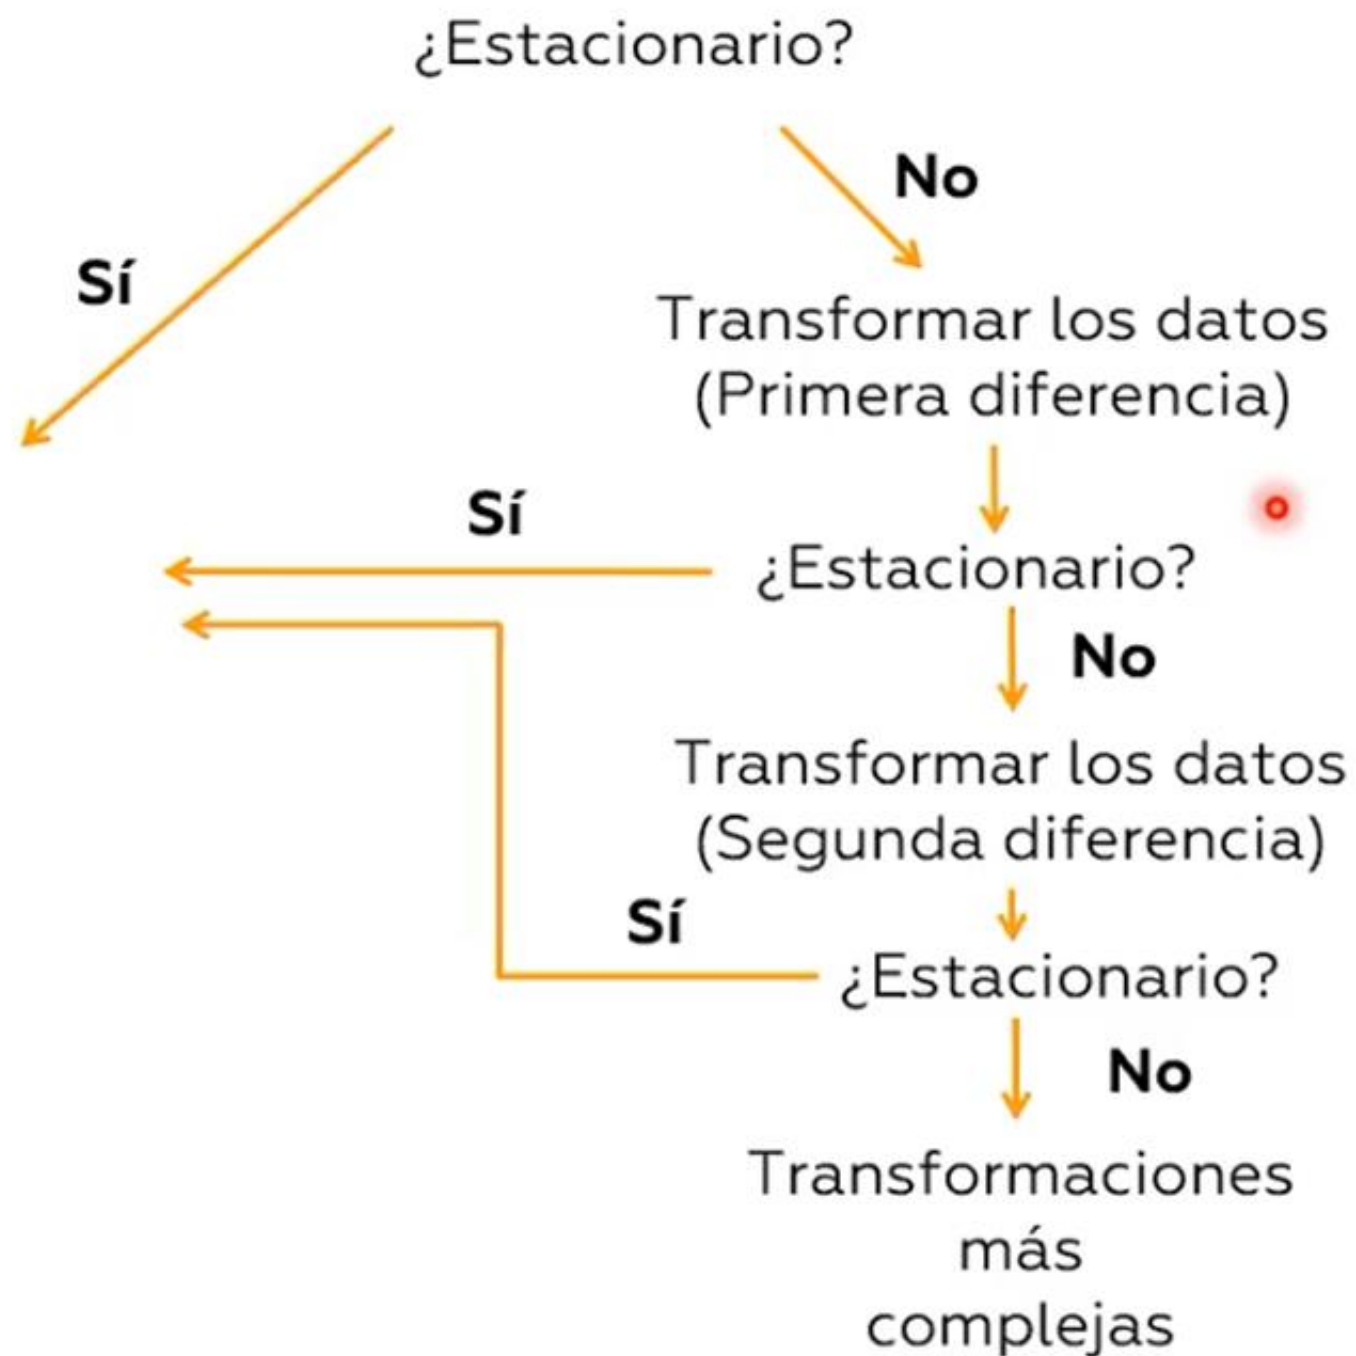
Estacionariedad en los modelos ARIMA


b) **Tendencia en media** o tendencia (sin más). Una de las formas más elementales de eliminar esta tendencia es proceder a calcular **diferencias sucesivas** de la misma. Así, si la serie y_t muestra tendencia en media, posiblemente ya no la tendrá con la siguiente transformación:

$$\Delta y_t = y_t - y_{t-1}$$

El proceso contrario a la **diferenciación** es la **integración**. De este modo, las series que necesitan de **1 diferencia** para ser estancionarias en media se dice que son **integradas de orden 1**:



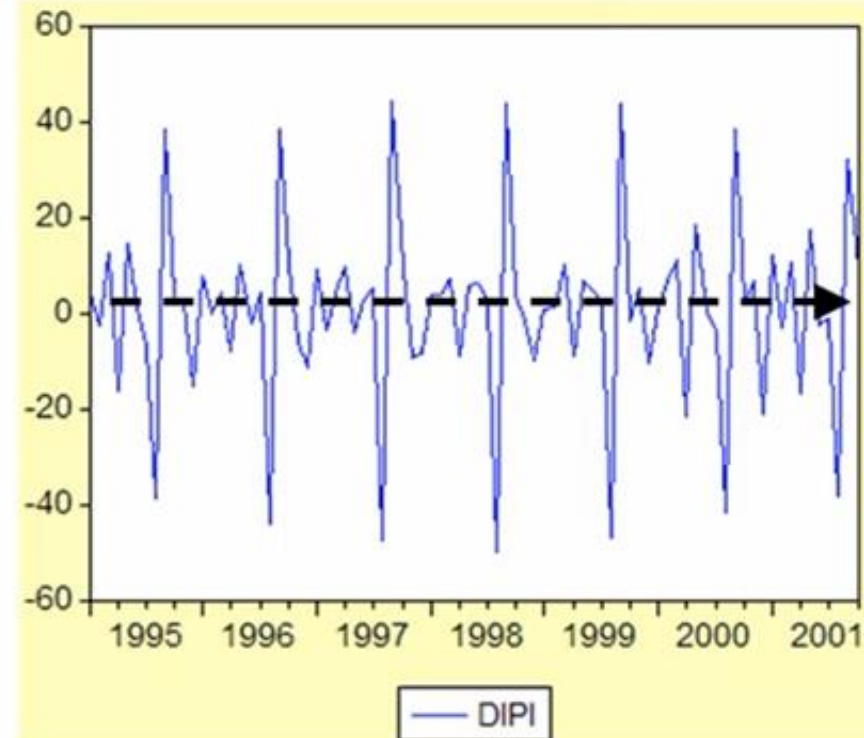





Ejemplo:

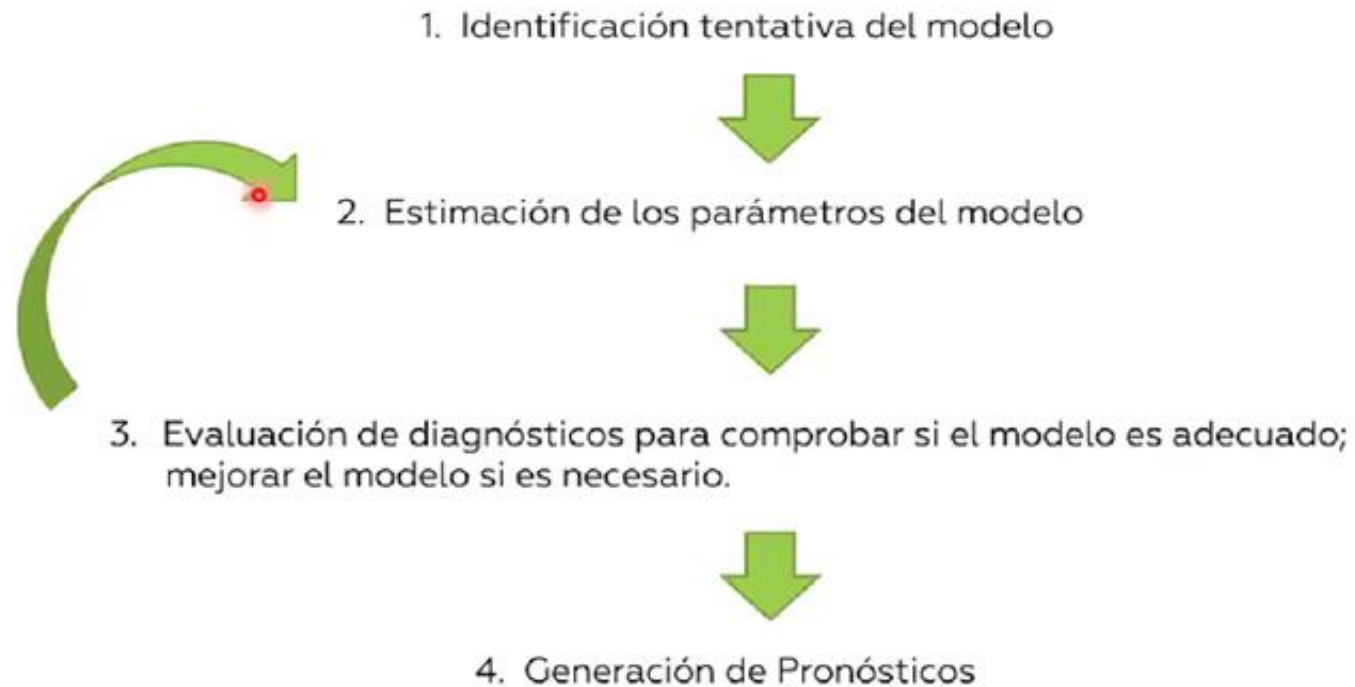
1) Serie original = IPI

2) Transformación logarítmica: $LIPI = \text{LOG}(IPI)$



3) Transformación en primeras diferencias: $DIPI = IPI - IPI(-1)$

Esquema de escoger modelos series temp



Análisis de residuos

H0: Los residuos son ruido blanco

H1: no es ruido blanco

Ruido blanco significa que el Error:

Media igual a cero

Varianza constante

No estar serialmente correlacionada

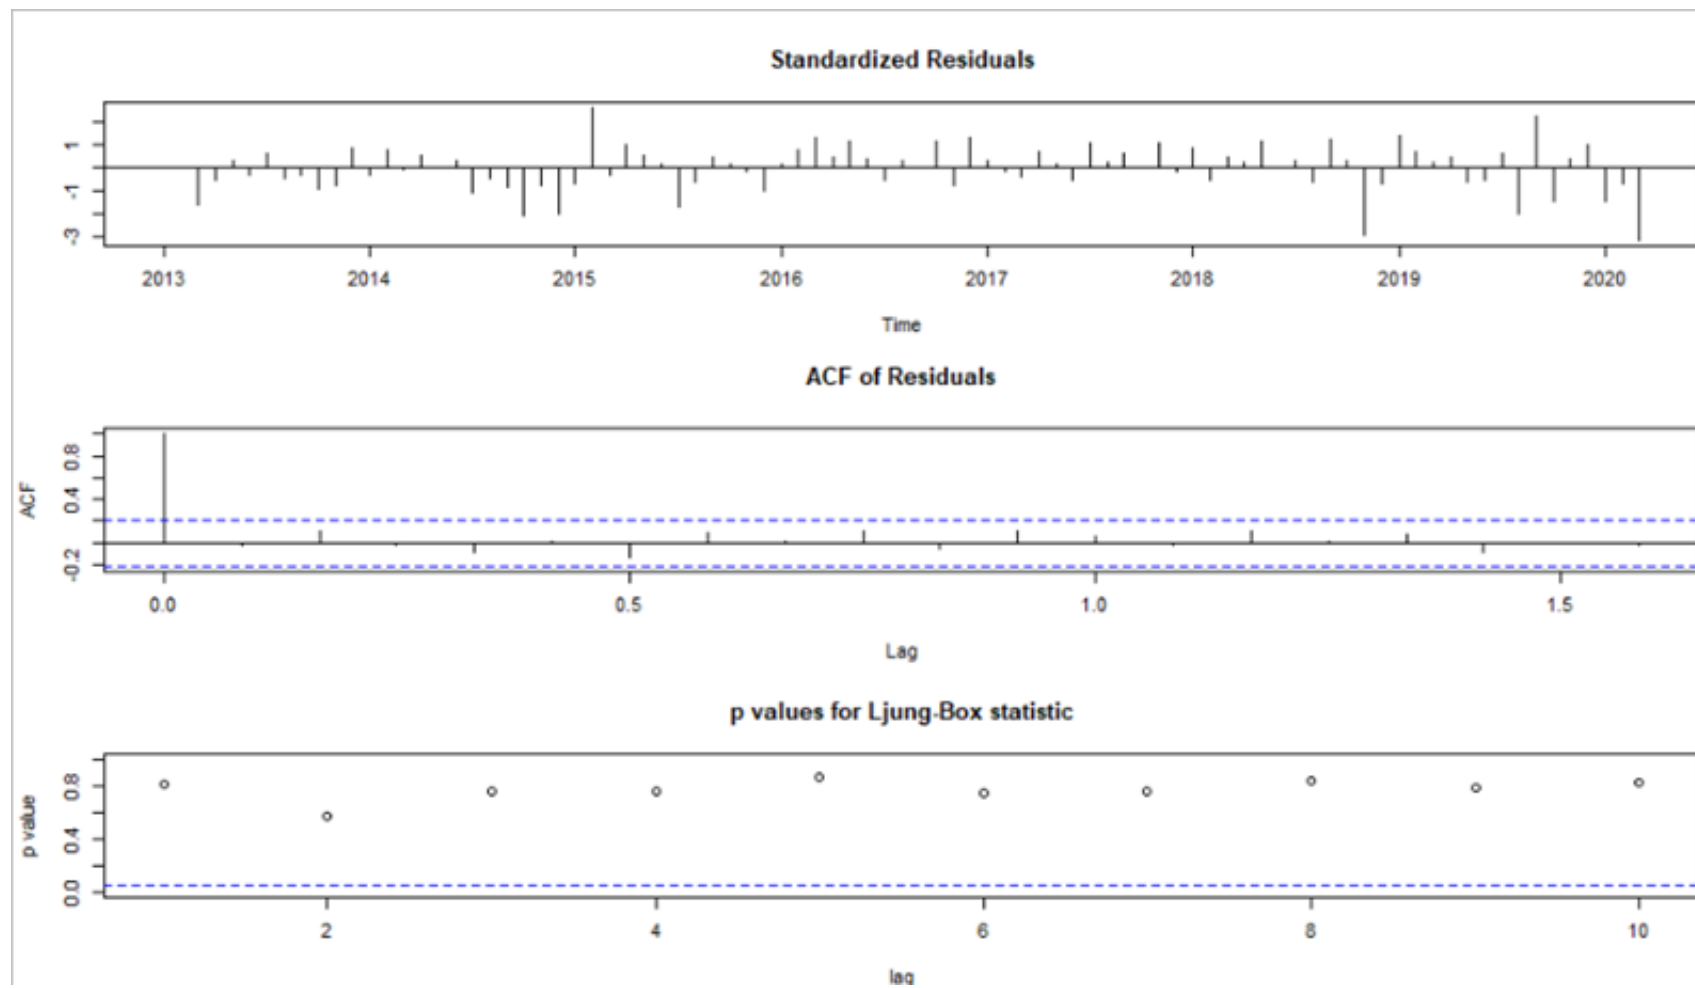
```
> Box.test(residuals(modelo1), type="Ljung-Box")
```

Box-Ljung test

```
data: residuals(modelo1)
```

```
X-squared = 0.055048, df = 1, p-value = 0.8145
```

Análisis de residuos



Modelos SARIMAX

SARIMAX (1, 0, 2) (2, 0, 1, 5)

$$y_t = c + \varphi_1 y_{t-1} + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \Phi_1 (y_{t-5} + \varphi_1 y_{t-6}) + \\ \Phi_2 (y_{t-10} + \varphi_1 y_{t-11}) + \Theta_1 (\varepsilon_{t-5} + \theta_1 \varepsilon_{t-6} + \theta_2 \varepsilon_{t-7}) + \varepsilon_t$$